



KLEINRÄUMIGE EXTRAPOLATION VON UMFRAGEDATEN

NAMEN:	ALEXANDER LANGE, KAI HUSMANN
MATR. NR.:	21426614, 20707176
STUDIENGANG:	ANGEWANDTE STATISTIK
MAIL:	ALEXANDER.LANGE@UNI-GOETTINGEN.DE KAI.HUSMANN@FORST.UNI-GOETTINGEN.DE
KURS:	STATISTISCHES PRAKTIKUM
KURSLEITER:	PROF.DR. THOMAS KNEIB
LEHRSTUHL:	STATISTIK
FAKULTÄT:	WIRTSCHAFTSWISSENSCHAFTEN
ABGABEDATUM:	30. SEPTEMBER 2016

INHALTSVERZEICHNIS

1 Einleitung	1
2 Material und Methoden	2
2.1 Daten	2
2.1.1 Parametrisierungsstichprobe	2
2.1.2 Bürgerumfrage	6
2.1.3 Zensus	7
2.2 Statistische Methoden	9
2.2.1 Modell	9
2.2.2 Modellwahl	9
2.3 Konfidenzbänder	9
2.4 Kreuzvalidierung	10
2.5 Validierung	10
3 Ergebnisse	11
3.1 Modellwahl	11
3.2 Reklassifizierung	11
3.3 Kreuzvalidierung	12
3.4 Validierung	12
3.5 Extrapolation	12
4 Diskussion	12
5 Fazit	13
Literatur	16
Anhang	17

ABBILDUNGSVERZEICHNIS

1	Endogene Variablen der Parameterisierungsstichprobe.	4
2	Kontur Plot der absoluten Anzahl der Gruppenbeobachtungen zur Meinung zu Stuttgart 21 in drei Gruppen. Quelle der Hintergrundgrafik: REF: Google Maps .	5
3	Kontur Plot der absoluten Anzahl der Gruppenbeobachtungen zur Wohnzufriedenheit in fünf Gruppen. Quelle der Hintergrundgrafik: REF: Google Maps	6
4	Anteile zur Meinung zu Stuttgart 21 nach Stadtbezirken.	7
5	Anteile der Meinung zu Stuttgart 21 nach Stadtteilen.	8
6	Illustration geschätzte gegen wahre Anteile für Gauss-Krüger Informationen extrapoliert auf die Bürgerumfrage mit zwei und drei Klassenmodell mit 95% Quantilen	13
7	Vergleich der extrapolierten Gesamtanteile für Stuttgart mit allen geschätzten Modellen und beiden Extrapolationsdateien mit den wahren Anteilen, sowie den Anteilen der Stichprobe mit 95% Quantilen zur Meinung zu Stuttgart 21	14
8	Vergleich der extrapolierten Gesamtanteile für Stuttgart mit allen geschätzten Modellen und beiden Extrapolationsdateien mit den Anteilen der Stichprobe mit 95% Quantilen zur Bewertung der Wohngegend	15
9	Anteile der Bewertung der Wohngegend nach Stadtbezirken.	18
10	Anteile der Bewertung der Wohngegend nach Stadtteilen. Wegen der deutlichen Unterschiede in den Anteilen sind die Farbskalen nicht einheitlich, sondern unterscheiden sich in den Diagrammen.	19

TABELLENVERZEICHNIS

1	Erhobene sozioökonomische und geographische Variablen der Parameterisierungsstichprobe und deren Anzahl der Ausprägungen sowie vermutete Modellierung im additiven Modell.	2
2	Erhobene sozioökonomische und geographische Variablen der Bürgerumfrage und deren Anzahl der Ausprägungen.	7
3	Erhobene sozioökonomische und geographische Variablen der Bürgerumfrage und deren Anzahl der Ausprägungen.	8
4	Reklassifizierung der Meinung zu Stuttgart 21	11
5	Reklassifizierung der Bewertung der Wohngegend	11
6	Vergleich der mittleren quadratischen Abweichung (MSE) und der Überdeckungswahrscheinlichkeit bei allen Prognosen aus den geschätzten Modellen und den beiden Extrapolationsdateien für die Meinung zu Stuttgart 21	12

1 EINLEITUNG

Die Grundgesamtheit dieser Unteruchung ist die Bevölkerung Stuttgarts. Fragestellungen: Wie ist die Wohzufriedenheit in Stuttgart? Wie ist die Meinung zu Stuttgart 21? Kleinräumige Extrapolation test

2 MATERIAL UND METHODEN

2.1 DATEN

Insgesamt liegen für die Analysen drei Umfragen mit unterschiedlichen Stichprobenumfängen vor. Die kleinste Datei enthält Angaben zur Bewertung der Wohngegend, der Meinung zu Stuttgart 21 sowie weitere sozioökonomische Kovariablen, die zur Erklärung der beiden abhängigen Variablen dienen sollen. Die Datei wird im Folgenden als Parametrisierungsstichprobe bezeichnet. Bei der Parametrisierungsumfrage handelt es sich folglich um eine Stichprobe von der die Grundgesamtheit für eine Validierung nicht zur Verfügung steht. Alle Modellqualitätskriterien müssen entweder an der Stichprobe selbst oder an den beiden separat erhobenen Umfragen angewendet werden. Diese beiden anderen Umfragen haben jeweils einen deutlich größeren Stichprobenumfang. An diesen Umfragen werden die parametrisierten Modelle angewendet und die Meinung zu Stuttgart 21 sowie die Wohnzufriedenheit somit kleinräumig extrapoliert. Einige Variablen unterscheiden sich in ihren Ausprägungen zwischen den Umfragen. Zur Vereinheitlichung der Dateien mussten einige Gruppenausprägungen demnach umkodiert werden. Die Umkodierungen können in der digital anhängenden Datei *Aufbereitung_Stuttgart21.R* nachvollzogen werden.

2.1.1 PARAMETRISIERUNGSTICHPROBE

Mit den Datensätzen der Parametrisierungsstichprobe (Tabelle 1) werden die Modelle zur kleinräumigen Extrapolation parametrisiert. Insgesamt beinhaltet die Umfrage 8 sozioökonomische Variablen und Angaben zur räumlichen Lage. Von jedem Datensatz sind die stetige räumliche Lage als Gauss-Krüger Geokoordinate sowie die diskrete räumliche Lage in Stadtteil und Stadtbezirk bekannt.

TABELLE 1: ERHOBENE SOZIOÖKONOMISCHE UND GEOGRAPHISCHE VARIABLEN DER PARAMETERISIERUNGSTICHPROBE UND DEREN ANZAHL DER AUSPRÄGUNGEN SOWIE VERMUTETE MODELLIERUNG IM ADDITIVEN MODELL.

Anzahl Beobachtungen: 3.143

Variable	Anzahl Ausprägungen	Modellierung
Bewertung Wohngegend	6	Geordnet Kategorial
Meinung Stuttgart 21	6	Geordnet Kategorial
Personenanzahl im Haushalt	5	Nicht Parametrisch
Monatliches Netto Haushaltseinkommen	6	Nicht Parametrisch
Altersklasse Befragter	6	Nicht Parametrisch
Geschlecht	2	Parametrisch
Familienstand	4	Parametrisch
Nationalität	2	Parametrisch
Stadtbezirk	23	Markov-Zufallsfeld
Stadtteil	142	Markov-Zufallsfeld
Gauß-Krüger		Tensorprodukt-Splines

||||| HEAD In der Tabelle sind nicht nur die Kategorienanzahlen der Variablen, sondern auch die vermuteten Formen der Einflüsse der Kovariablen auf die abhängigen Variablen aufgelistet.

Diese wurden durch visuelle Darstellung aller Kovariablen über den abhängigen Variablen ermittelt. Nach visueller Einschätzung ergab sich, dass alle nominal skalierte Variablen, wie z.B. die Nationalität, parametrisch linear und dass alle kardinal skalierte Variablen, wie z.B. die Altersklasse des Befragten, offensichtlich als nicht parametrisch modelliert werden sollten. Diese beobachteten Zusammenhänge finden sich häufig in Regressionsmodellen, da eine lineare Modelle oft nicht flexibel genug sind um kardinal oder metrisch skalierte Zusammenhänge beschreiben zu können [Fahrmeir et al., 2009, p. 9]. In Anlehnung an [Fahrmeir et al., 2013, p. 503 ff., p. 524 ff.] wird der räumliche Effekt entweder kontinuierlich als Tensor Produkt oder diskret als Gauß-Markov Zufallsfeld modelliert.

Für die Auswahl der geeigneten Regressionsmethode ist es hilfreich, das Verhältnis der Häufigkeiten der Kategorienausprägungen der abhängigen Variable zu kennen und seltene Ereignisse zu identifizieren. Während die meisten befragten Personen ihre Wohngegend mit *gut* oder *sehr gut* bewertet haben, Ereignisse mit schlechterer Einschätzung folglich deutlich seltener auftreten, sind die Gruppenhäufigkeiten der Antworten zum Projekt Stuttgart 21 näherungsweise gleichverteilt. In beiden Fällen wurden die wenigen, für die Modellierung irrelevanten Kategorien *Keine Angabe* entfernt. In beiden Fällen kann den Gruppen eine Rangfolge, jedoch kein Intervall Abstand unterstellt werden. Es handelt sich demnach jeweils um ordinal Skalierte Daten.
===== In der Tabelle sind nicht nur die Kategorienanzahlen der Variablen, sondern auch die vermuteten Formen der Einflüsse der Kovariablen auf die abhängigen Variablen aufgelistet. Diese wurden durch visuelle Darstellung aller Kovariablen über den abhängigen Variablen ermittelt. Nach visueller Einschätzung ergab sich, dass alle nominal skalierten Variablen, wie z.B. die Nationalität, als parametrisch und dass alle kardinal skalierte Variablen, wie z.B. die Altersklasse des Befragten, offensichtlich als nicht parametrisch modelliert werden sollten. Diese beobachteten Zusammenhänge finden sich häufig in Regressionsmodellen [Fahrmeir et al., 2009, p. 9]. In Anlehnung an [Fahrmeir et al., 2013, p. 503 ff., p. 524 ff.] wird der räumliche Effekt entweder kontinuierlich als Tensor Produkt oder diskret als Gauss-Markov Zufallsfeld modelliert.

Für die Auswahl der geeigneten Regressionsmethode ist es hilfreich, das Verhältnis der Häufigkeiten der Kategorienausprägungen der abhängigen Variable zu kennen und seltene Ereignisse zu identifizieren. Während die meisten befragten Personen haben ihre Wohngegend mit *gut* oder *sehr gut* bewertet, treten Beobachtungen mit schlechterer Einschätzung folglich deutlich seltener auf. Die sind die Gruppenhäufigkeiten der Antworten zum Projekt Stuttgart 21 sind zudem näherungsweise gleichverteilt. In beiden Fällen wurden die wenigen, für die Modellierung irrelevanten Kategorien *Keine Angabe* entfernt. In beiden Fällen kann den Gruppen eine Rangfolge, jedoch kein Intervall Abstand unterstellt werden. Es handelt sich demnach jeweils um ordinal Skalierte Daten. *l*lli*lli 0e7a5f093e308c8021ea752650976a5e78c83317*

Das amtliche, nach Stadtteilen oder Stadtbezirken aufgelöste Ergebnis der Bürgerumfrage zu Stuttgart 21 von 2011 kann dem Internetauftritt der Stadt entnommen werden [Stuttgart, 2011]. Es bietet sich dadurch eine zusätzliche Möglichkeit zur Modellevaluierung an. Da hier mit Sicherheit nur 2 Kategorien (*Zustimmung, Ablehnung*) unterschieden werden können, wurden die Daten dieser Arbeit neu gruppiert. Es wurde eine Neugruppierung in 3 (*Zustimmung, Neutral, Ablehnung*, Tabelle 1, links) sowie in zwei Gruppen (*Zustimmung, Ablehnung*) vorgenommen. Für die exogen in die Analyse einfließenden Variablen sind detailliertere Informationen zu den Häufigkeiten der Ausprägungen im Anhang verfügbar (REF ABB A.1).

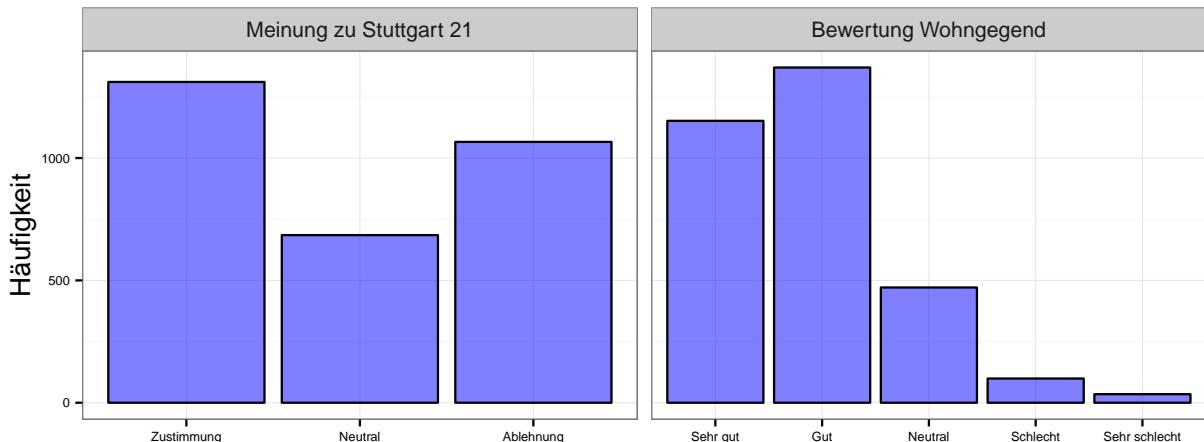


ABBILDUNG 1: ENDOGENE VARIABLEN DER PARAMETERISIERUNGSSTICHPROBE.

Da in dieser Arbeit ein Schwerpunkt auf der Analyse unterschiedlicher räumlicher Effekte liegt, vergleicht dieser Abschnitt alle drei räumlichen Effekte in Relation zu den beiden endogenen Variablen. Abbildung 2 zeigt die absolute Häufigkeit der Beobachtungen der Meinung zu Stuttgart 21 in kontinuierlicher räumlicher Lage. Zur besseren Übersicht wurden nicht alle Beobachtungen geplottet, sondern Beobachtungsdichten über bivariate normalverteilte Kerndichteschätzer mit festem Abstand für jede Richtungen ermittelt (REF ggplot2, MASS). Um die Hintergrundkarte einbinden zu können wurden die Gauß-Krüger Koordinaten in Dezimalgrad umgerechnet. Da absolute Dichten dargestellt werden, ist zunächst ersichtlich, in welchen Bereichen die meisten Bürger leben. Wegen der hohen Einwohnerdichte im Innenstadtbereich sind dort die Beobachtungsdichten aller 3 Klassen tendenziell höher als in den Randbezirken. Des weiteren ersichtlich ist, dass einige Bereiche, wie das Naturschutzgebiet *Rotwildpark* im Westen oder der *Schurwald* im Osten, aufgrund ihrer geographischen Beschaffenheit oder Landnutzungsform nicht oder nur sehr dünn besiedelt sind.

Die *Zustimmung* zeigt offensichtliche räumliche Muster. Im Zentrum und im Nordosten ist sie höher als im Rest der Stadt. Der räumliche Trend der *Ablehnung* ist schwächer ausgeprägt. Es zeigt sich jedoch, dass der Bereich der Innenstadt, sowie die südlichen Stadtbereiche etwas höhere Dichten bei der *Ablehnung* aufweisen. Die Beobachtungen der Kategorie *neutral* sind eher gleichmäßig über die Stadt verteilt.

Abbildung 3 zeigt die Dichte der Beobachtungen der fünf Kategorien zur Bewertung der Wohngegend. Hier zeigt sich ein deutlich ausgeprägteres räumliches Muster als bei der Meinung zu Stuttgart 21. Die Beobachtungen der Klasse *sehr gut* häufen sich sehr stark im Innenstadtbereich und im Süden. Die Kategorie *gut* verteilt sich relativ homogen über das gesamte Stadtgebiet mit einer etwas stärkeren Konzentration in der Innenstadt und im Nordosten. Bei der Kategorie *neutral* zeigt sich eine stärkere Konzentration auf den Osten und Nordosten der Stadt. Praktisch alle *schlechten* und *sehr schlechten* Bewertungen sind deutlich abgegrenzt im Osten und Nordosten lokalisiert. Hierbei ist zu erwähnen, dass der Anteil der Personen, die ihre Wohngegend mit *schlecht* oder *sehr schlecht* bewertet haben sehr gering ist Abbildung 1.

Im folgenden werden die diskreten räumlichen Informationen auf Stadtbezirksebene beschrie-

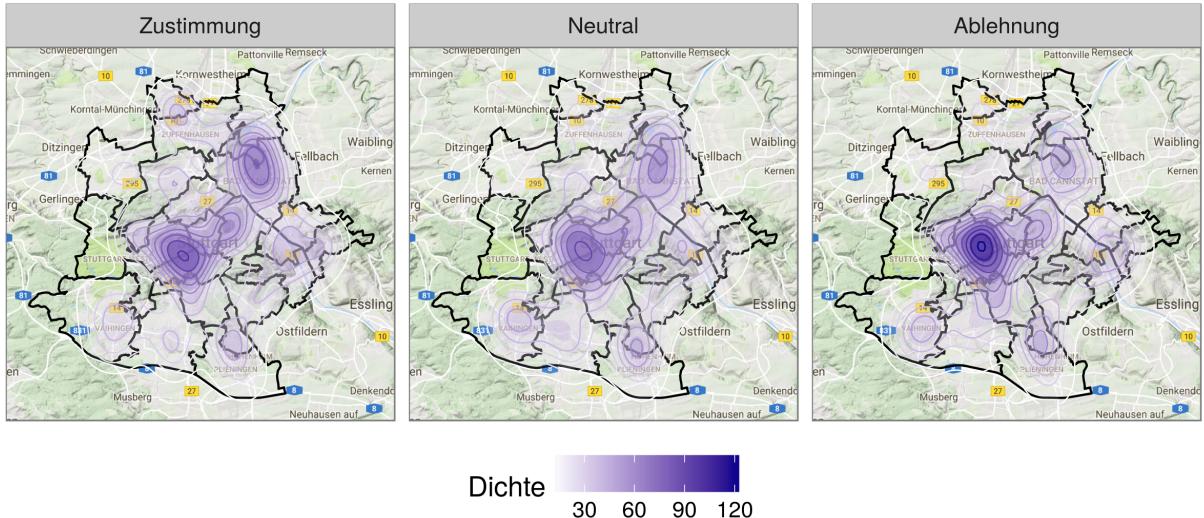


ABBILDUNG 2: KONTUR PLOT DER ABSOLUTEN ANZAHL DER GRUPPENBEZOGBACHTUNGEN ZUR MEINUNG ZU STUTTGART 21 IN DREI GRUPPEN. QUELLE DER HINTERGRUNDGRAFIK: REF: GOOGLE MAPS

ben. Es werden 23 Stadtbezirke unterschieden. Im Gegensatz zur stetigen Beobachtungsdichte werden die Beobachtungen nach Regionen aggregiert dargestellt, wodurch eine relative Anteilsdarstellung möglich wird (Abbildung 4). Die Darstellung wird also weniger von der absoluten Gesamtbevölkerungsdichte in den Regionen überdeckt. Analog zur stetigen Darstellung (Abbildung 2) ist auch hier zu sehen, dass die Bürger des Nordostens eine positivere Meinung zu Stuttgart 21 haben als die Bürger aus dem Süden. Die neutrale Klasse hat in allen Bezirken einen geringeren Anteil und es ist kein räumliches Muster erkennbar. Die entsprechenden Anteilsgrafen mit fünf Klassen für die Bewertung der Wohngegend sind im Anhang verfügbar (Abbildung 9). Wie in Abbildung 3 bereits angedeutet, zeigen sich negative Wohngebietseinschätzungen vor allem im Nordosten.

Die dritte und letzte untersuchte räumliche Aggregationsebene ist die Stadtteilebene. Abbildung 5 zeigt die räumliche Verteilung von *Zustimmung*, *Ablehnung* und *neutraler* Haltung. Wie aus Tabelle 1 hervorgeht, ist die Stadtteilebene deutlich feiner Auflöst als die Bezirksebene. Dies führt in der Abbildung dazu, dass einige Stadtteile mit geringer Gesamteinwohneranzahl in einer oder mehreren Klassen keine Beobachtungen zeigen. Es gibt demnach auch Stadtteile, in denen die komplementäre Klasse zu 100 % vertreten ist. Des weiteren gibt es in dieser Aggregationsebene sogar Stadtteile ohne jede Beobachtung, wie z. B. das Benzviertel im Innenstadtbereich oder die bereits angesprochenen Lagen im Westen.

Diese Stadtteile werden in den Diagrammen schwarz dargestellt. Wegen der feineren Auflösung ergibt sich ein mosaikartiges, visuell schwerer interpretierbares Bild. In keiner der drei Klassen lässt sich eine klare Struktur oder räumliches Muster erkennen. Die Anteile auf Stadtteilebene zu der Bewertung der Wohngegend sind im Anhang verfügbar 10. Hier zeigt sich ein ähnlich schwer differenzierbares Muster wie bei der Meinung zu Stuttgart 21. Wegen der deutlichen Unterschiede in den Anteilen der fünf Gruppen sind die Farbskalen nicht einheitlich, sondern

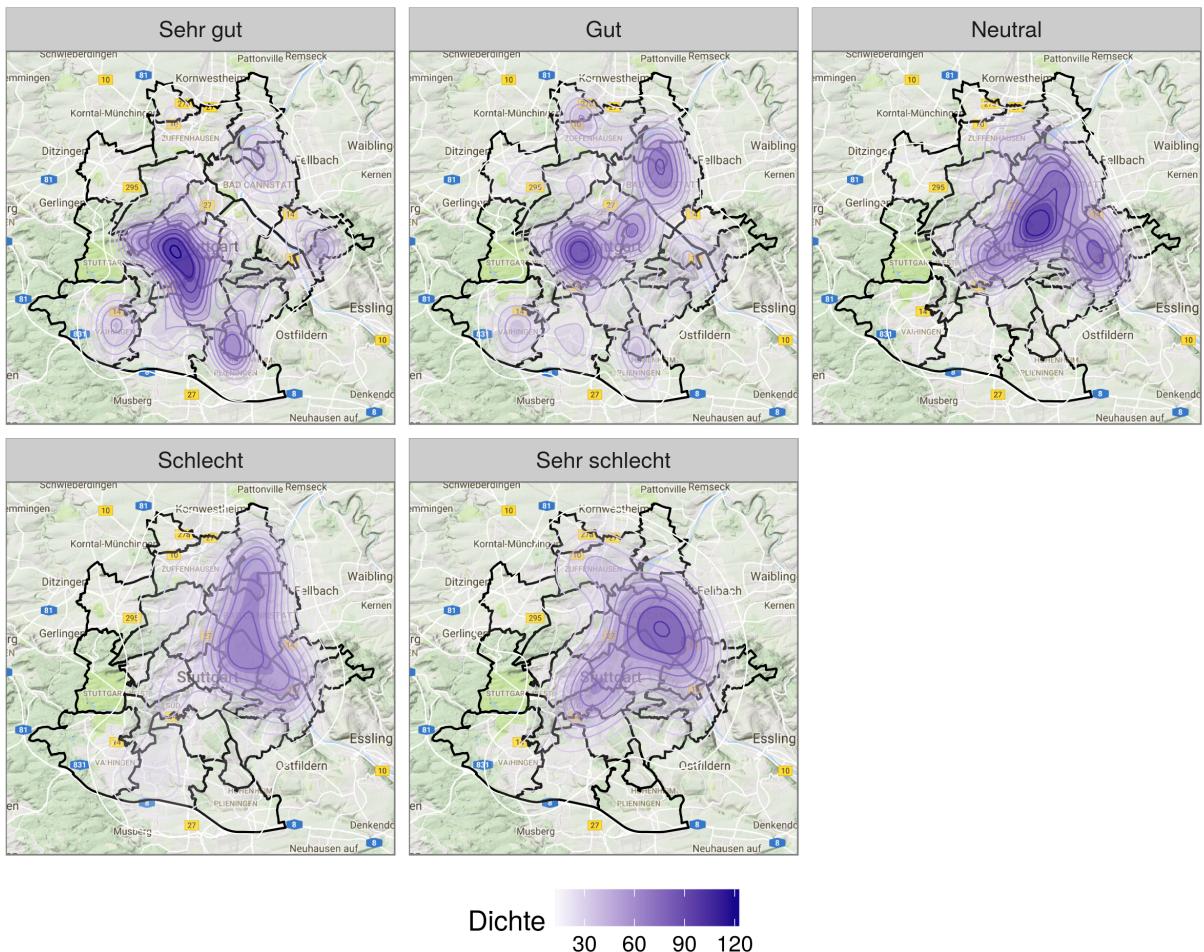


ABBILDUNG 3: KONTUR PLOT DER ABSOLUTEN ANZAHL DER GRUPPENBEZOGLICHEN ZUR WOHNZUFRIEDENHEIT IN FÜNF GRUPPEN. QUELLE DER HINTERGRUNDGRAFIK: REF: GOOGLE MAPS

unterscheiden sich in den Diagrammen.

2.1.2 BÜRGERUMFRAGE

In der Bürgerumfrage von 20?? wurden 470.190 Bürger zu acht sozioökonomischen Punkten befragt. Der Stichprobenumfang dieser Umfrage liegt also relativ nah an der Grundgesamtheit von 573.104 Bürgern, die 2011 mit Hauptwohnsitz in Stuttgart gemeldet waren (REF Stat. Bundesamt). Von allen Befragten liegt der Wohnsitz als kontinuierliche Gauss-Krüger Geokoordinate vor. Um eine kleinräumige Extrapolation mit diskreten räumlichen Informationen vornehmen zu können, wurden die Stadtteil- und Stadtbezirksinformationen an die Datei angehängt. Hierzu wurden die Stadtteil- und Stadtbezirkspolygone, welche uns von der Stadt Stuttgart zur Verfügung gestellt wurden, über eine räumliche Abfrage mit der Bürgerumfrage Datei verknüpft. Die Geoanalyse wurde mit dem freien Geoinformationssystem QGIS (REF) durchgeführt. Die Projektdatei mit der Geoabfrage (*Geographische_Abfrage.QGS*) sowie die Shapefiledateien (*Stadtteile_netto.SHP*) liegen dieser Arbeit digital bei. Wie in den Tabellen 1 und REF

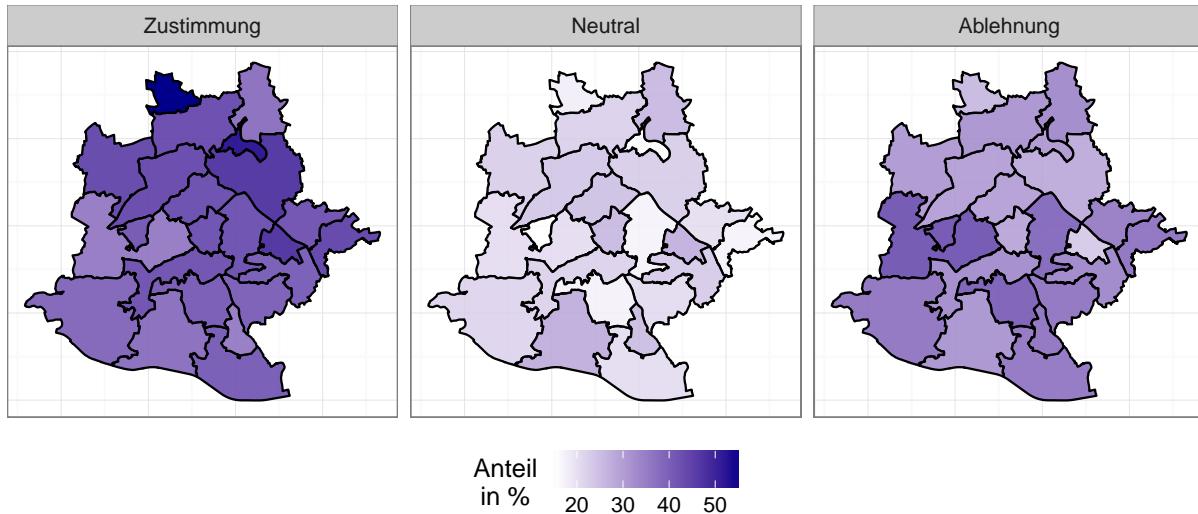


ABBILDUNG 4: ANTEILE ZUR MEINUNG ZU STUTTGART 21 NACH STADTBEZIRKEN.

? ersichtlich eignen sich nicht alle Variablen zur Extrapolation, da nicht alle Variablen in jeder Umfrage erhoben wurden. Es ergibt sich ein Überschneidungsbereich der fünf sozioökonomischen Variablen *Altersklasse Befragter, Geschlecht, Nationalität, Familienstand und Personenzahl im Haushalt*. IN TAB 2 BRAUCHEN WIR DIE SPALTE MODLLEIRUNG EIGENTLICH NICHT MEHR ODER? ICH HABE DIE VARIABLEN Z.T. UMBEBENANNT, DAMIT SIE GLEICH HEIßEN WIE IN TAB 1. AUßerdem sind ja nach dem Umkodieren bei der Altersklasse nur noch 6 Auspr. Ich würde das in der Tab. 2 anpassen was meinst du?

TABELLE 2: ERHOBENE SOZIOÖKONOMISCHE UND GEOGRAPHISCHE VARIABLEN DER BÜRGERUMFRAGE UND DEREN ANZAHL DER AUSPRÄGUNGEN.

Anzahl Beobachtungen: 470.190

Variable	Modellierung	Anzahl Ausprägungen
Altersklasse Befragter	Nicht Parametrisch	14
Geschlecht	Parametrisch	2
Nationalität	Parametrisch	2
Familienstand	Parametrisch	4
Personenzahl im Haushalt	Nicht Parametrisch	5
Wohndauer	Nicht Parametrisch	3
ALG II Quote	Nicht Parametrisch	9
Ein/Zweifamilienhäuser	Nicht Parametrisch	8
Gauß-Krüger	Tensorprodukt-Splines	

2.1.3 ZENSUS

Im Rahmen der bundeweiten Volkszählung von 2011 wurden in Stuttgart 380.238 Bürger befragt REF TAB 3. Da beim Zensus auch für die Fragestellung dieser Arbeit relevante sozioökonomische

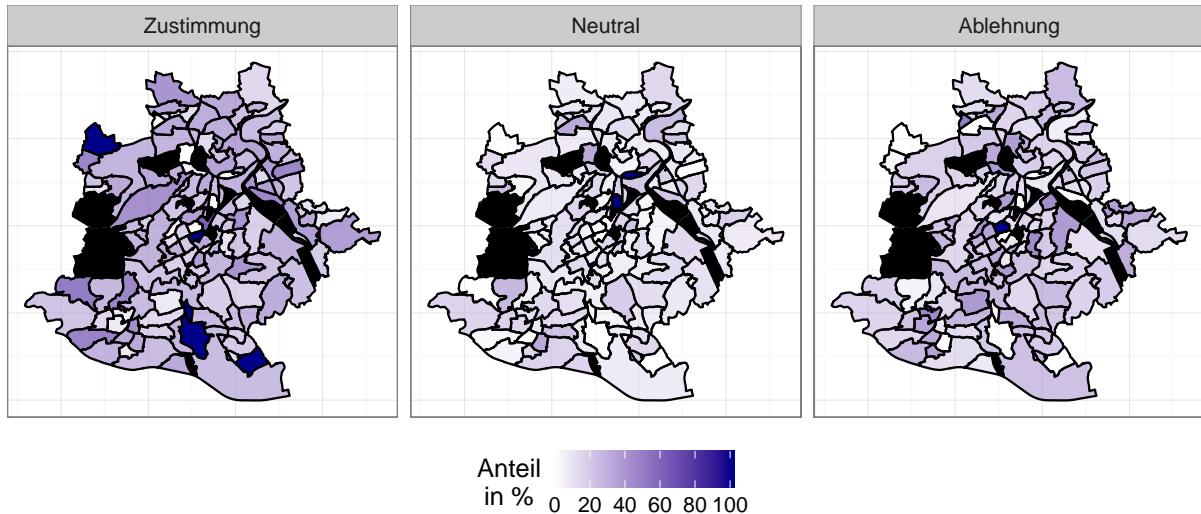


ABBILDUNG 5: ANTEILE DER MEINUNG ZU STUTTGART 21 NACH STADTTEILEN.

Variablen erhoben wurden, eignet sich diese Umfrage ebenfalls für die kleinräumige Extrapolation. Die diskreten geographischen Angaben wurden analog zur Bürgerumfrage per geographischer Abfrage ergänzt. Für die kleinräumige Extrapolation eignen sich die gleichen möglichen sozioökonomischen Variablen wie bei der Bürgerumfrage. Wie in Tab. 2.: Habe die Namen angepasst. Anzahl Personenzahl und Alter umkodiert, also auch in Tabelle ändern? Wir könnten sogar überlegen, die nicht verwendeten Variablen zu löschen. Wir gehen ja im Text nicht mehr auf diese ein (gilt auch für Tab 2)

TABELLE 3: ERHOBENE SOZIOÖKONOMISCHE UND GEOGRAPHISCHE VARIABLEN DER BÜRGERUMFRAGE UND DEREN ANZAHL DER AUSPRÄGUNGEN.

Anzahl Beobachtungen: 380.238

Variable	Modellierung	Mögliche Ausprägungen
Altersklasse Befragter	Nicht Parametrisch	9
Geschlecht	Parametrisch	2
Nationalität	Parametrisch	2
Familienstand	Parametrisch	4
Personenzahl im Haushalt	Nicht Parametrisch	6
Wohnfläche	Nicht Parametrisch	24
Stellung Beruf	Parametrisch	9
Beamter	Parametrisch	2
Gebäudetyp	Parametrisch	10
Gebäudenutzung	Parametrisch	2
Gauß-Krüger	Tensorprodukt-Splines	

2.2 STATISTISCHE METHODEN

2.2.1 MODELL

Kurze Erläuterung GAM und logit,... Zusammengesetzt aus parametrischen Effekten und Splines. Pseudobeobachtungen. Wahl des Glättungsparameters (Wood 2000).

2.2.2 MODELLWAHL

Basierend auf den vorhergegangenen Analysen des Beamten- und Eigenheimanteils in Stuttgart wurde die R Funktion `stepAIC()` zur schrittweisen AIC [Akaike, 1981] Berechnung programmiert, die zur Identifikation der geeignetsten Kovariablenkombination dient. In der Funktion werden mithilfe der `gam()` Funktion des `mgcv` Paketes [Wood, 2011] generalisierte additive Modelle mit unterschiedlichen Kovariablen erstellt und deren AIC berechnet. Vor dem Aufruf der Funktion müssen die abhängige Variable, die Verteilungsannahme des Regressionsmodells, die Gewichtungen der Einzelbeobachtungen und unveränderliche Kovariablen definiert werden. Außerdem muss eingeschätzt werden, welche der veränderlichen Kovariablen parametrisch oder semiparametrisch als Spline in das Modell eingehen. Es wird zunächst der AIC des einfachsten, nur aus den fest vorgegebenen Kovariablen bestehenden Modells berechnet. In Iteration eins werden alle veränderlichen Kovariablen einzeln nacheinander in die Modellformel aufgenommen und es wird jeweils ein GAM erstellt sowie dessen AIC berechnet. Die Kovariablen gehen entsprechend der vorigen Eingabe parametrisch oder semiparametrisch ein. Falls die Hinzunahme mindestens einer Kovariable in Iteration eins zu einer Reduktion des AIC führt, wird diejenige Kovariable, welche zu dem Modell mit dem kleinsten AIC führt zur Modellformel hinzugefügt. Falls das Modell nur mit den festen Modellbestandteilen bereits den geringsten AIC zeigt ist die Modellwahl folglich in Iteration eins bereits beendet.

Andernfalls setzt sich das Ausgangsmodell für Iteration zwei aus den festen Kovariablen und einer weiteren Kovariable zusammen. In Iteration zwei werden wie zuvor alle verbleibenden Kovariablen zunächst nacheinander zur aktuellen Modellformel hinzugefügt. Wenn die Kovariable mit dem geringsten AIC gefunden ist (falls diese existiert und das Modell aus Iteration eins nicht bereits das geeignete ist), werden alle veränderbaren Kovariablen in Iteration zwei nochmals nacheinander eliminiert. Das Modell mit dem geringsten AIC bildet das Ausgangsmodell der nächsten Iteration. Dies wird wiederholt bis in einer Iteration kein Modell mit einem geringeren AIC als in der vorigen Iteration parametrisiert werden kann. Um die Laufzeit der Funktion zu begrenzen, wurde auf die Analyse von Wechselwirkungen zwischen den Kovariablen verzichtet. Wechselwirkungen können jedoch als unveränderliche Modellbestandteile eingehen.

2.3 KONFIDENZBÄNDER

Die Intervalle der Punktschätzungen liefern zusätzliche wichtige Informationen, da die Punktschätzungen alleine keine Angaben zur Unsicherheit enthalten. Mit dem Vertrauensintervall erhält man die Relation der Unsicherheit zur Punktschätzung zur Unsicherheit und somit ein weiteres Modellgütemerkmal [Fahrmeir et al., 2013][p. 471]. Des weiteren eignen sich Konfidenzintervalle zur Formulierung von Hypothesentests und zur Berechnung von Überdeckungswahrscheinlichkeiten bestimmter Werte von Interesse. Grundsätzlich gibt es die Möglichkeit Intervalle aus den Modellinformationen abzuleiten oder Bootstrap-Intervalle durch wiederholte zufällige Reparametri-

sierung des Modells zu berechnen. Bei ersterem Vorgehen sind, je nach Methode, oft zusätzliche Annahmen, beispielsweise zur Verteilung oder zur Symmetrie, der Intervalle zu treffen. Aus diesen Gründen wurden punktweise Bootstrap-Intervalle für jede Punktschätzung berechnet.

Zur Berechnung der Intervalle wurde jedes Modell 1.000 mal mit einer Zufallsstichprobe (*Ziehen-mit-Zurücklegen*) aus der Parameterisierungsstichprobe parametrisiert. Um den Einfluss des Stichprobenumfangs zu eliminieren, enthielt jede Stichprobe die tatsächliche Anzahl der Beobachtungen. Aus den Wiederholungen wurden arithmetischer Mittelwert, Median, unteres sowie oberes 95 % Perzentil berechnet.

2.4 KREUZVALIDIERUNG

Für die Modellerstellung der additiven Modelle lag eine Stichprobe von 3.143 vor. Außer der Gesamtindividuenanzahl (573.104 gemeldete Bürger) lagen keine Informationen zur Grundgesamtheit vor. Die Qualität der Modelle ließ sich folglich nicht an der Grundgesamtheit validieren sondern musste an der Stichprobe selbst eingeschätzt werden. Zu diesem Zweck wurde eine *Leave-One-Out* Kreuzvalidierung durchgeführt [Fahrmeir et al., 2013][p. 149], in welcher jeweils eine Beobachtung zufällig entfernt wurde. Die verbleibenden Beobachtungen wurden genutzt, um ein additives Modell zu erstellen, mit dem die entfernte Beobachtung vorhergesagt wurde. Mit diesen Daten ließ sich ein Statistik zu den korrekt reklassifizierten Beobachtungen erstellen.

2.5 VALIDIERUNG

Ziel der Validierung ist es, die prognostizierten Anteile aus dem gewählten Modell mit den wahren Anteilen aus der Volksabstimmung [Stuttgart, 2011] zu vergleichen, um eine Aussage über die Qualität der geschätzten Prognosemodelle geben zu können. Die Validierung erfolgt auf Stadtteil- und Bezirksebene, sowie für das Gesamtergebnis der Stadt Stuttgart. Dazu werden insbesondere zwei statistische Gütemaße verwendet.

Bei der Wahl des Schätzers geht es zum einen darum, einen möglichst erwartungstreuen als auch effizienten Schätzer zu finden. Als geeignetes Gütemaß hat sich die mittlere quadratische Abweichung erwiesen, da sie sowohl die Varianz, als auch die quadrierte Verzerrung berücksichtigt. Zudem hat ein konsistenter Schätzer die Eigenschaft, dass die mittlere quadratische Abweichung bei unendlich groß werdender Stichprobe gegen Null konvergiert [Georgii, 2009, p. 201]. Ein weiteres Kriterium ist die Überdeckungswahrscheinlichkeit. Sie gibt an, mit welcher Wahrscheinlichkeit das geschätzte Konfidenzintervall den wahren Wert enthält. Erwartet wird hier, dass die Überdeckungswahrscheinlichkeit dem Konfidenzniveau entspricht. Mögliche größere Abweichungen können durch die Approximation einer diskreten Verteilung durch eine stetige Verteilung resultieren, was z.B. oft bei der Approximation der Binomial- durch die Normalverteilung vorkommt [Lawrence D. Brown, 2001, p. 102].

3 ERGEBNISSE

3.1 MODELLWAHL

3.2 REKLASSIFIZIERUNG

Die Ergebnisse der Reklassifizierung zur Meinung zu Stuttgart 21 (Tabelle 4) zeigen, dass die Erfolgsquote im drei Klassenmodell zwischen 44% und 50% liegen und im zwei Klassenmodell zwischen 55% und 62% liegen. Zum Vergleich mit einem reinen Zufallsmodell, dass im drei Klassenmodell eine Erfolgswahrscheinlichkeit von $1/3$ und im zwei Klassenmodell von $1/2$ hat, weißen die geschätzten Modelle eine höhere Erfolgsquote auf. Auch bei einem Vergleich mit Tabelle 1 zeigt sich, dass die geschätzten Modelle besser abschneiden, als ein triviales wählen der immer gleichen Klasse.

TABELLE 4: REKLASSIFIZIERUNG DER MEINUNG ZU STUTTGART 21

		Geoadditives Modell	Modell ohne räumlichem Effekt	Modell nur mit räumlichem Effekt
Drei Kl.	Gauss-Krüger	0,4918	0,4716	0,4732
	Bezirke	0,4726	0,4719	0,4726
	Stadtteile	0,451	0,4685	0,4449
Zwei Kl.	Gauss-Krüger	0,6193	0,6104	0,5524
	Bezirke	0,6079	0,6104	0,5515
	Stadtteile	0,6282	0,6052	0,6099

Des weiteren ist zu sehen, dass das Geoadditive Modell in fast allen Fällen die höchste Erfolgsquote aufweist. Abweichungen bestehen im drei Klassenmodell mit Stadtteilen als räumlicher Effekt und im zwei Klassenmodell mit Bezirken als räumlicher Effekt. Außerdem ist zu beachten, dass im drei Klassenmodell das Modell nur mit räumlichem Effekt besser abschneidet als das Modell ohne räumlichem Effekt, während sich für zwei Klassen diese Situation umgekehrt hat. Für die Reklassifikation der Bewertung der Wohngegend (Tabelle 5) ergibt sich eine Erfolgsquote zwischen 40% und 50%. Damit ist auch hier eine Verbesserung gegenüber reinem Raten oder dauerhaftem wählen einer Klasse gegeben.

TABELLE 5: REKLASSIFIZIERUNG DER BEWERTUNG DER WOHNGEEND

		Geoadditives Modell	Modell ohne räumlichem Effekt	Modell nur mit räumlichem Effekt
Gauss-Krüger	0,4922	0,4461	0,4896	
	0,4701	0,4461	0,4621	
	0,4046	0,4204	0,4347	

Für die Modelle mit den kontinuierlichen Gauss-Krüger Informationen und den Bezirken als räumlichen Effekt hat das Geoadditive Modell die höchste Erfolgsrate, wohingegen für die Stadtteilinformationen das Modell nur mit räumlichem Effekt die beste Reklassifizierung aufweist. Insgesamt schneidet das Geoadditive Modell für beide endogene Variablen und alle drei möglichen Klassenanzahlen am besten ab. Außer bei dem zwei Klassenmodell zur Meinung zu Stuttgart 21 weisen beim Geoadditivem Modell die Gauss-Krüger Informationen als räumliche Effekte die höchste und die Stadtteile als räumliche Effekte die niedrigste Erfolgsrate auf.

Da Modelle ohne räumlichen Effekt in der AIC-Untersuchung und Kreuzvalidierung stets schlechter Abschnitten, wurden die Ansätze ohne räumliche Effekte nicht weiter verfolgt.

3.3 KREUZVALIDIERUNG

3.4 VALIDIERUNG

TABELLE 6: VERGLEICH DER MITTLEREN QUADRATISCHEN ABWEICHUNG (MSE) UND DER ÜBERDECKUNGSWAHRSCHEINLICHKEIT BEI ALLEN PROGNOSEN AUS DEN GESCHÄTZTEN MODellen UND DEN BEIDEN EXTRAPOLATIONSDATEIEN FÜR DIE MEINUNG ZU STUTTGART 21

		MSE		Überdeckungswk.	
		Zustimmung	Ablehnung	Zustimmung	Ablehnung
Gauss-Krüger	Bez.	U	0,04	0,749	1
		Z	0,116	0,557	0,391
	Sadtt.	U	0,461	5,708	0,954
		Z	0,813	4,415	0,553
3 Kl. Bezirke	Bez.	U	0,041	0,756	1
		Z	0,117	0,562	0,522
	Stadtteile	U	0,482	5,678	0,934
		Z	0,835	4,38	0,567
Stadtteile	Bez.	U	0,022	0,903	
		Z	0,081	0,593	
	Stadtteile	U	0,453	6,69	
		Z	0,61	4,641	
Gauss-Krüger	Bez.	U	0,312	0,312	0,826
		Z	0,152	0,152	0,522
	Stadtteile	U	2,694	2,679	0,649
		Z	1,581	1,569	0,46
2 Kl. Bezirke	Bez.	U	0,312	0,312	0,826
		Z	0,153	0,153	0,565
	Stadtteile	U	2,642	2,645	0,636
		Z	1,527	1,513	0,433
Stadtteile	Bez.	U	0,468	0,468	
		Z	0,201	0,201	
	Stadtteile	U	3,741	3,723	
		Z	1,906	1,893	

3.5 EXTRAPOLATION

4 DISKUSSION

Die beiden Datensätze zur Grundgesamtheit stammen aus einer Bürgerumfrage mit 470.190 Beobachtungen und dem Zensus mit 380.238 Beobachtungen. Im Verhältnis zu den Grundgesamtheiten dieser Größenordnung sind 3143 Beobachtungen in der Stichprobe relativ gering, was eine gewisse Unsicherheit für die Extrapolation mit sich bringt [...].

Weiterhin ist zu beachten, dass Informationen zu dem monatlichen Netto Haushaltseinkommen in beiden Grundgesamtheiten fehlen und somit die Variable nicht für die Prognose verwendet werden kann. Auch war eine denkbare Erstellung von Proxy-Variablen nicht möglich. Eine ge-

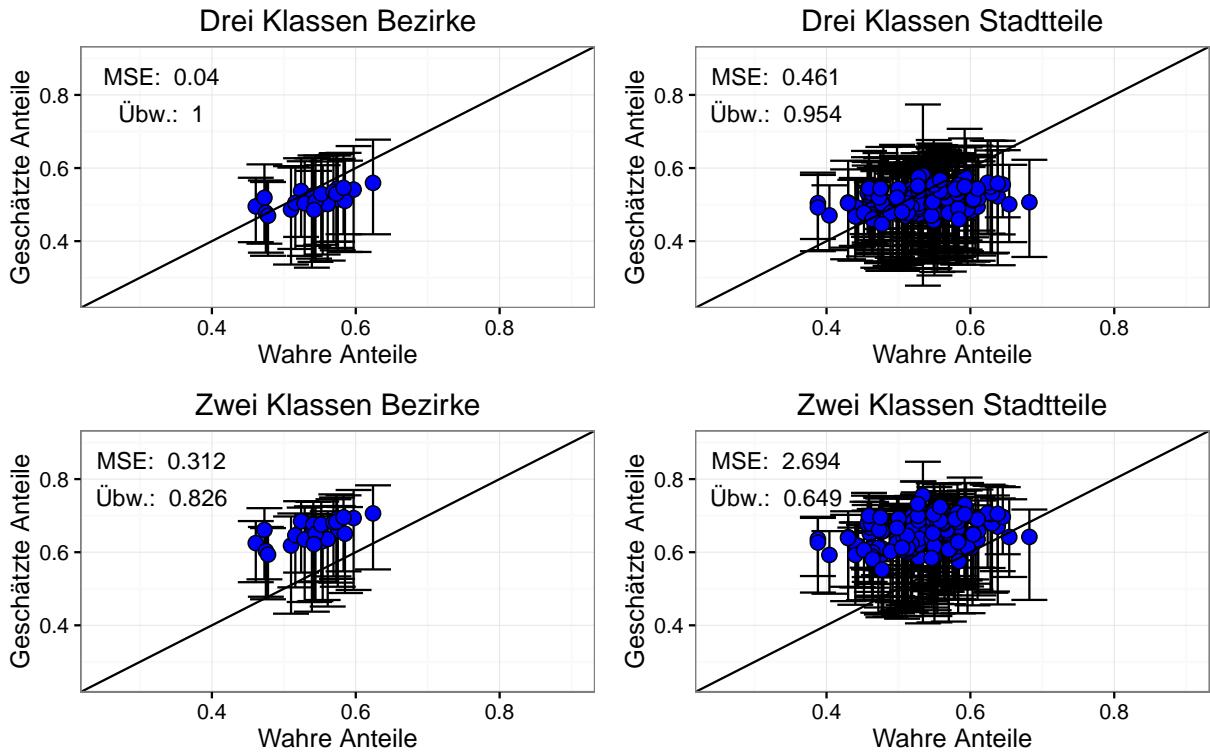


ABBILDUNG 6: ILLUSTRATION GESCHÄTZTE GEGEN WAHRE ANTEILE FÜR GAUSS-KRÜGER INFORMATIONEN EXTRAPOLIERT AUF DIE BÜRGERUMFRAGE MIT ZWEI UND DREI KLASSEN-MODELL MIT 95% QUANTIELEN

naue Auflistung der enthaltenen Variablen aus den Grundgesamtheiten ist im Anhang verfügbar. Die Arbeit zielt darauf ab, die Meinung der Befragten zu dem Projekt Stuttgart 21 und die Zufriedenheit mit der Wohngegend der Befragten auf die Grundgesamtheit zu extrapolieren. Daher ist es sinnvoll die Ausprägungen dieser Variablen genauer zu untersuchen.

Insgesamt ist zu sagen, dass die Gauss-Krüger Informationen ein relativ klaren Einblick in die Verteilung der Beobachtungen in der jeweiligen Klasse geben. Bei den diskreten räumlichen Informationen könnte die grobe Aufteilung auf Bezirksebene zu einem Underfitting und die sehr feine Aufteilung auf Stadtteilebene zu einem Overfitting führen [...]. Zudem ist zu vermuten, dass die räumlichen Informationen einen stärkeren Effekt auf die Bewertung der Wohngegend haben, als auf die Meinung zu Stuttgart 21.

5 FAZIT

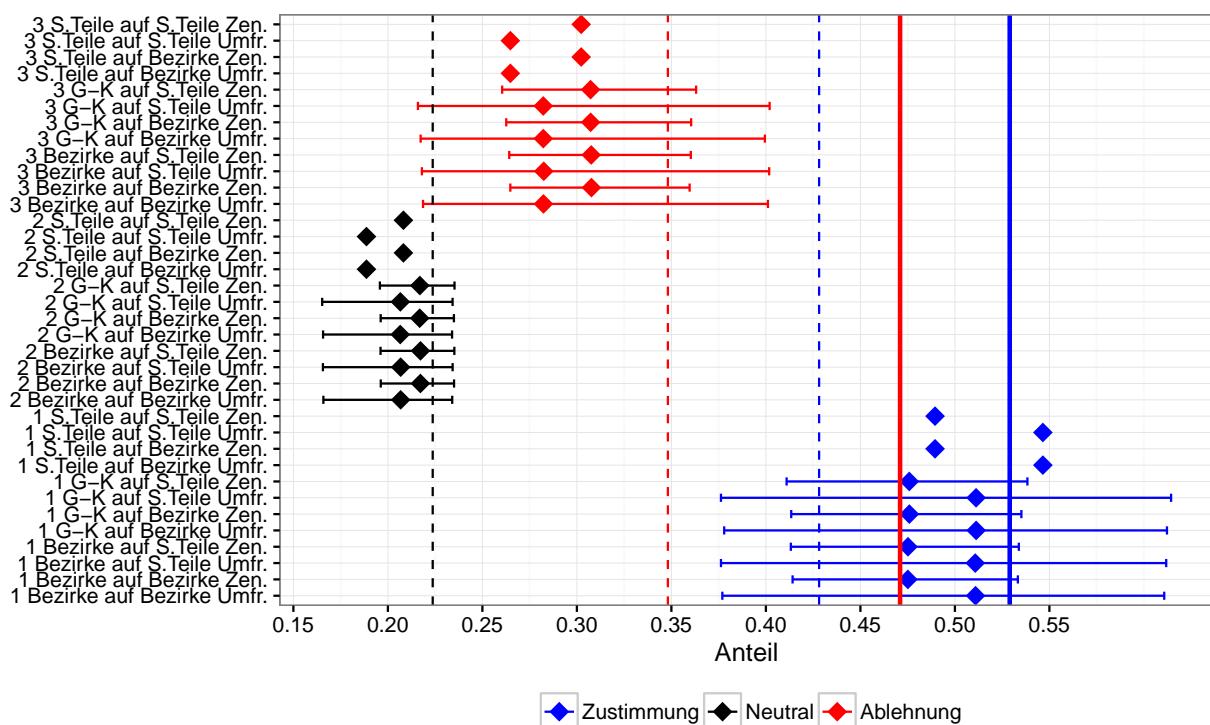


ABBILDUNG 7: VERGLEICH DER EXTRAPOLIERTEN GESAMTANTEILE FÜR STUTTGART MIT ALLEN GESCHÄTZTEN MODELLEN UND BEIDEN EXTRAPOLATIONSDATEIEN MIT DEN WAHREN ANTEILEN, SOWIE DEN ANTEILEN DER STICHPROBE MIT 95% QUANTILEN ZUR MEINUNG ZU STUTTGART 21

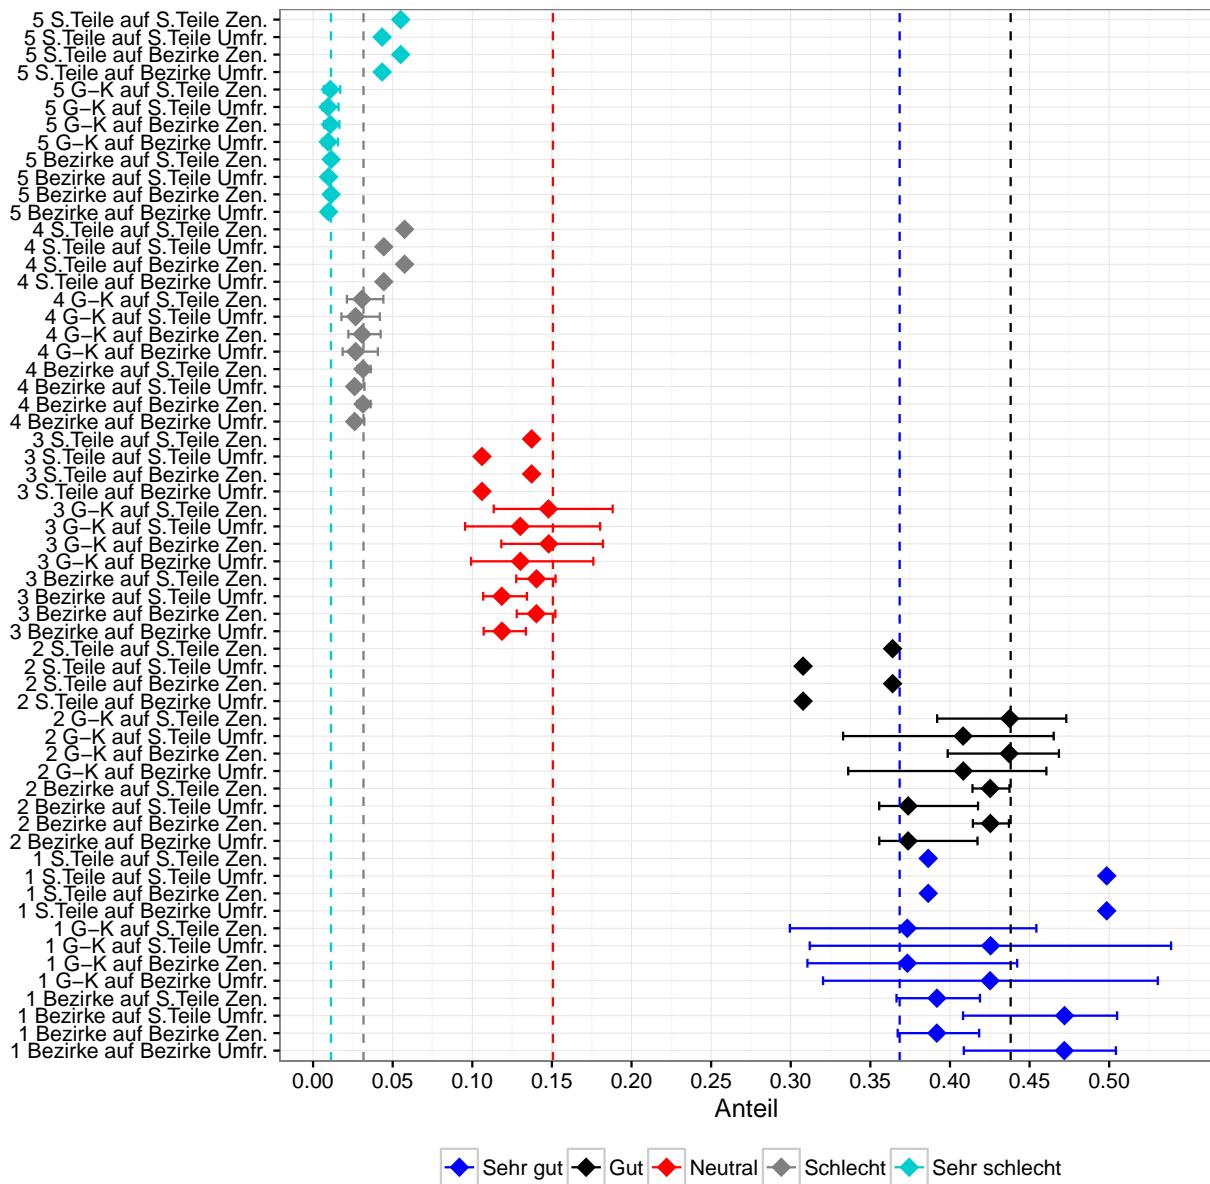


ABBILDUNG 8: VERGLEICH DER EXTRAPOLIERTEN GESAMTANTEILE FÜR STUTTGART MIT ALLEN GESCHÄTZTEN MODELLEN UND BEIDEN EXTRAPOLATIONSDATEIEN MIT DEN ANTEILEN DER STICHPROBE MIT 95% QUANTILEN ZUR BEWERTUNG DER WOHNGEgend

LITERATUR

- [Akaike, 1981] Akaike, H. (1981). Likelihood of a model and information criteria. *Journal of Econometrics*, pages 3–14.
- [Fahrmeir et al., 2009] Fahrmeir, L., Kneib, T., and Lang, S. (2009). *Regression. Statistik und ihre Anwendungen*. Springer Berlin Heidelberg.
- [Fahrmeir et al., 2013] Fahrmeir, L., Kneib, T., Lang, S., and Marx, B. (2013). *Regression: Models, Methods and Applications*. Springer, Dordrecht.
- [Georgii, 2009] Georgii, H.-O. (2009). *Stochastik. Einführung in die Wahrscheinlichkeitstheorie und Statistik*. Walter de Gruyter.
- [Lawrence D. Brown, 2001] Lawrence D. Brown, T. Tony Cai, A. D. (2001). Interval estimation for a binomial proportion. *Statistical Science*.
- [Stuttgart, 2011] Stuttgart, S. (2011). <http://www.stuttgart.de/volksabstimmung>.
- [Wood, 2011] Wood, S. N. (2011). Fast stable restricted maximum likelihood and marginal likelihood estimation of semiparametric generalized linear models. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 73(1):3–36.

ANHANG

ANHANG

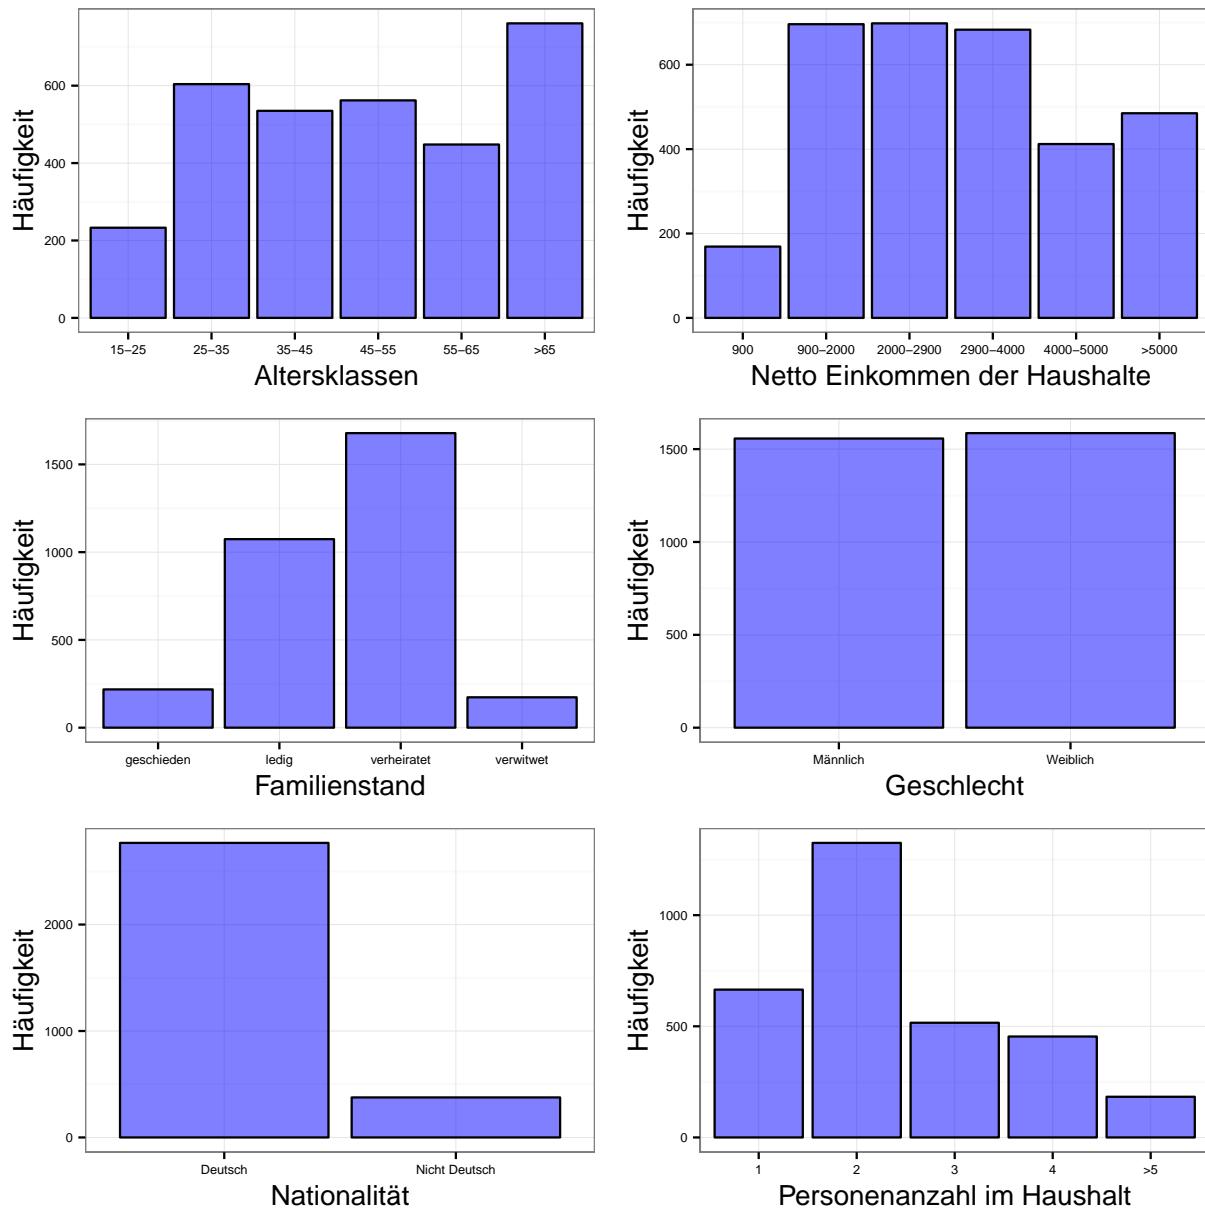


ABBILDUNG 9: ANTEILE DER BEWERTUNG DER WOHNGEgend NACH STADTBEZIRKEN.

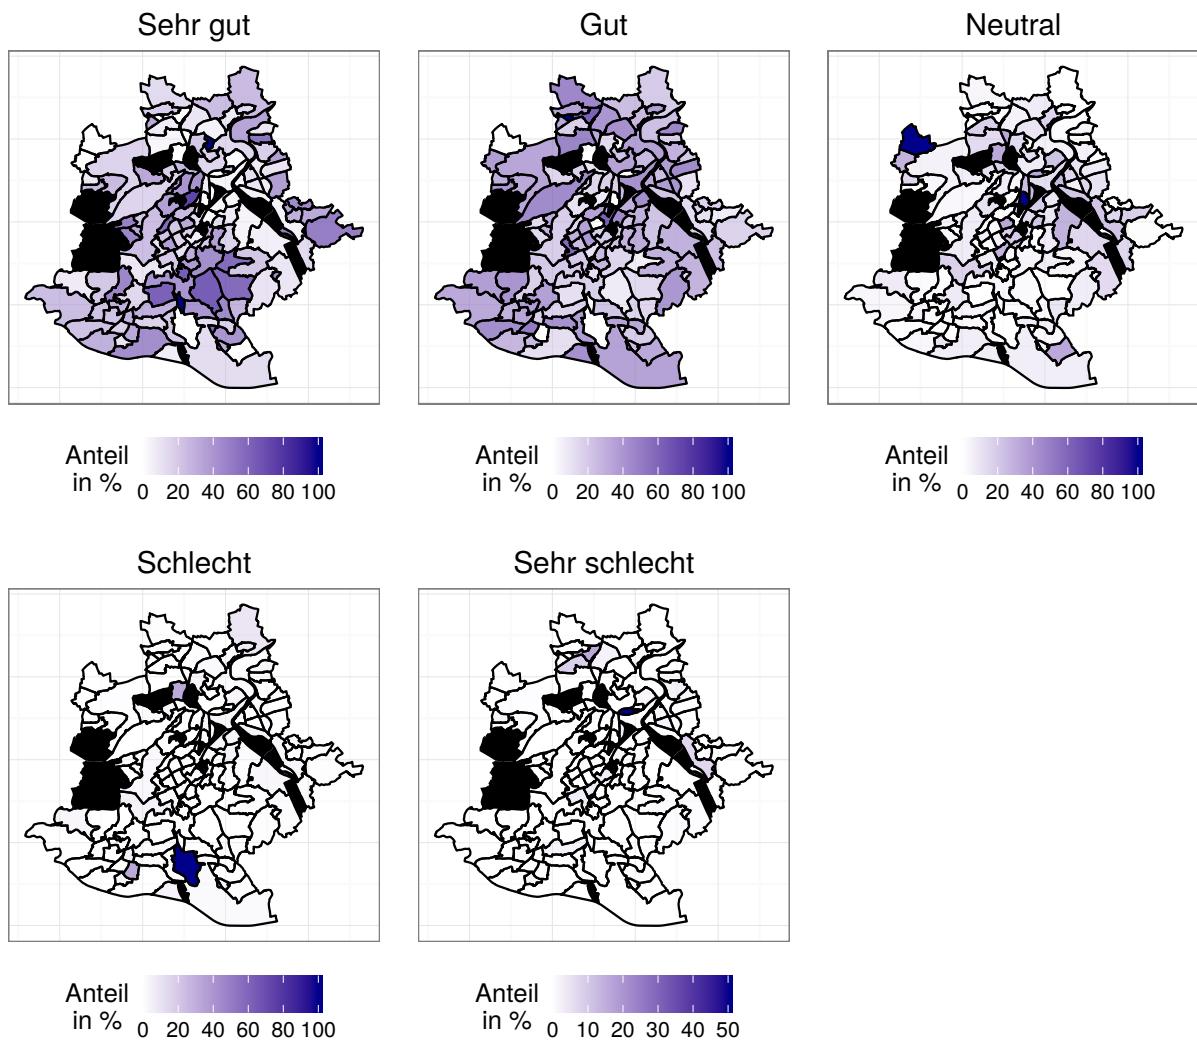


ABBILDUNG 10: ANTEILE DER BEWERTUNG DER WOHNGEGEND NACH STADTTEILEN. WEGEN DER DEUTLICHEN UNTERSCHIEDE IN DEN ANTEILEN SIND DIE FARBSKALEN NICHT EINHEITLICH, SONDERN UNTERSCHIEDEN SICH IN DEN DIAGRAMMEN.

Hiermit versichere ich, dass ich die vorliegende Hausarbeit selbstständig verfasst und keine anderen als die angegebenen Hilfsmittel benutzt habe. Alle wörtlich oder sinngemäß den Schriften anderer entnommenen Stellen habe ich unter Angabe der Quellen kenntlich gemacht. Dies gilt auch für beigelegte Zeichnungen, Skizzen, bildliche Darstellungen und dergleichen.

Mir ist bewusst, dass ich mich im Falle einer unbeabsichtigten oder vorsätzlichen Missachtung durch den fehlerhaften Umgang mit Quellen unter Umständen strafbar mache und die vorliegende Hausarbeit mit nicht ausreichend bewertet wird.

Göttingen, den
Unterschrift

Hiermit erlaube ich, dass meine Arbeit auf Betrug und falsche, sowie fehlende Zitate auch online geprüft wird.

Mir ist bewusst, dass ich mich im Falle einer unbeabsichtigten oder vorsätzlichen Missachtung durch den fehlerhaften Umgang mit Quellen unter Umständen strafbar mache und die vorliegende Hausarbeit mit nicht ausreichend bewertet wird.

Göttingen, den
Unterschrift